

LAPORAN

**DETEKSI ANOMALI TRANSAKSI KARTU KREDIT
MENGUNAKAN ALGORITMA
ISOLATION FOREST**



Oleh:

**MUHAMMAD SAHAL ANWAR HADI
24260032**

**PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNIK DAN ILMU KOMPUTER
UNIVERSITAS NAHDLATUL ULAMA INDONESIA
JAKARTA
2026**

KATA PENGANTAR

Puji dan syukur penulis panjatkan ke hadirat Allah SWT atas rahmat dan karunia-Nya sehingga laporan yang berjudul "**Deteksi Anomali Transaksi Kartu Kredit Menggunakan Algoritma Isolation Forest**" ini dapat diselesaikan dengan baik.

Laporan ini disusun sebagai bentuk dokumentasi dari implementasi algoritma *Isolation Forest* dalam mendeteksi transaksi kartu kredit yang bersifat anomali (*fraud*) menggunakan dataset *Credit Card Fraud Detection* dari platform Kaggle. Seluruh proses mulai dari prapemrosesan data, pelatihan model, hingga evaluasi performa diimplementasikan menggunakan bahasa pemrograman Python dalam lingkungan Jupyter Notebook.

Penulis menyadari bahwa laporan ini masih jauh dari sempurna. Oleh karena itu, segala bentuk kritik dan saran yang membangun sangat penulis harapkan demi perbaikan di masa mendatang.

Akhir kata, penulis berharap laporan ini dapat memberikan manfaat dan menjadi referensi yang berguna bagi siapa pun yang membutuhkan, khususnya dalam bidang *machine learning* dan deteksi anomali data finansial.

Bogor, 26 Juni 2026

Penulis

DAFTAR ISI

KATA PENGANTAR.....	I
DAFTAR ISI.....	II
BAB 1 PENDAHULUAN	1
1.1 LATAR BELAKANG	1
1.2 RUMUSAN MASALAH.....	2
1.3 BATASAN MASALAH.....	2
1.4 TUJUAN PENELITIAN.....	3
1.5 MANFAAT PENELITIAN	3
1.6 METODE PENELITIAN.....	3
1.7 SISTEMATIKA PENULISAN.....	4
BAB 2 TINJAUAN PUSTAKA.....	6
2.1 PENELITIAN TERDAHULU.....	6
2.2 LANDASAN TEORI.....	9
BAB 3 METODOLOGI PENELITIAN.....	14
3.1 KERANGKA BERPIKIR	14
3.2 PENGUMPULAN DAN PENGOLAHAN DATA.....	15
3.3 PENGUMPULAN DATA.....	16
3.4 PERANCANGAN TEKNIK/MODEL (KEBAHARUAN)	19
3.5 EVALUASI TEKNIK/MODEL (<i>TEKNIK EVALUASI</i>).....	22
BAB 4 IMPLEMENTASI DAN EKSPERIMEN	25
4.1 PERSIAPAN DATA	25
4.2 IMPLEMENTASI TEKNIK/MODEL	27
4.3 HASIL DAN ANALISIS	30
BAB 5 PENUTUP.....	35
5.1 KESIMPULAN	35
5.2 SARAN	36
DAFTAR PUSTAKA.....	38
LAMPIRAN-LAMPIRAN	ERROR! BOOKMARK NOT DEFINED.

BAB 1

PENDAHULUAN

1.1 Latar Belakang

Di era digital saat ini, perkembangan transaksi elektronik mengalami pertumbuhan yang sangat pesat. Kemudahan, kecepatan, dan kenyamanan yang ditawarkan oleh layanan finansial berbasis digital (*fintech*), *mobile banking*, hingga *e-commerce* telah mengubah perilaku masyarakat dalam bertransaksi secara masif dari metode tunai menjadi non-tunai (Cherif et al., 2020).

Namun, lonjakan volume transaksi digital ini berbanding lurus dengan meningkatnya risiko kejahatan siber, khususnya penipuan (*fraud*). Aktivitas *fraud* pada kartu kredit tidak hanya merugikan konsumen dan institusi keuangan secara finansial, tetapi juga dapat menurunkan tingkat kepercayaan masyarakat terhadap ekosistem pembayaran digital (Devicharan Rai M & Jagadeesha S. N., 2023). Di dalam realitasnya, jumlah transaksi *fraud* ini sangatlah sedikit atau bersifat minoritas jika dibandingkan dengan volume transaksi normal (*imbalanced data*). Karakteristik *fraud* yang tersembunyi di antara jutaan transaksi normal, ditambah dengan polanya yang terus berevolusi, membuat proses deteksi secara manual oleh manusia menjadi sangat sulit, tidak efisien, dan rentan terhadap kesalahan (Ounacer et al., 2018).

Untuk mengatasi keterbatasan deteksi manual, teknologi *Machine Learning* hadir sebagai solusi mutakhir karena mampu menganalisis pola data dalam skala besar secara otomatis dan *real-time* (Vandana et al., 2023). Kendati demikian, sebagian besar metode klasifikasi konvensional dalam *Machine Learning* (*Supervised Learning*) membutuhkan data yang telah memiliki label (*labeled data*) secara akurat antara transaksi normal dan *fraud*. Dalam praktiknya, proses pelabelan data transaksi memerlukan waktu yang lama, biaya yang besar, serta keahlian khusus. Selain itu, algoritma klasifikasi standar sering kali mengalami penurunan performa (bias) ketika dihadapkan pada dataset yang sangat tidak seimbang (Waspada et al., 2020).

Sebagai alternatif, pendekatan *Unsupervised Learning* menjadi solusi yang lebih menjanjikan karena tidak bergantung pada ketersediaan label data. Salah satu metode yang dikenal efektif untuk kebutuhan ini adalah **Isolation Forest**. Berbeda dengan metode anomali tradisional yang berfokus pada pemodelan titik data normal, *Isolation Forest* secara eksplisit mengisolasi data yang menyimpang (anomali) menggunakan struktur pohon biner (Liu et al., 2008). Karena secara sifat dasarnya jumlah transaksi *fraud* itu sedikit dan memiliki atribut yang berbeda jauh dari transaksi normal, algoritma ini mampu memisahkan anomali tersebut

dengan lebih cepat dan efisien dibandingkan metode *unsupervised* lain seperti *Local Outlier Factor* (LOF) atau *One-Class SVM* (Ounacer et al., 2018).

Berdasarkan urgensi tersebut, penelitian ini dilakukan untuk menerapkan dan mengevaluasi performa algoritma *Isolation Forest* dalam mendeteksi aktivitas penipuan. Pengujian akan dilakukan menggunakan dataset **Credit Card Fraud Detection** guna mengetahui sejauh mana efektivitas pendekatan *unsupervised* ini dalam menangani kasus *fraud* kartu kredit yang memiliki ketimpangan data yang ekstrem (Waspada et al., 2020).

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah dipaparkan, maka rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana tahapan implementasi algoritma *Isolation Forest* pada dataset transaksi kartu kredit?
2. Sejauh mana kemampuan dan efektivitas algoritma *Isolation Forest* dalam mendeteksi transaksi yang bersifat anomali (*fraud*)?
3. Bagaimana performa hasil evaluasi model deteksi yang dibangun jika diukur menggunakan confusion matrix serta metrik evaluasi pendukung lainnya?

1.3 Batasan Masalah

Agar penelitian ini lebih terarah dan tidak keluar dari ruang lingkup yang direncanakan, maka diberikan batasan masalah sebagai berikut:

1. Dataset yang digunakan adalah dataset publik Credit Card Fraud Detection yang diperoleh dari platform Kaggle.
2. Algoritma Machine Learning yang diterapkan untuk mendeteksi anomali dibatasi hanya pada metode *Isolation Forest*.
3. Proses prapemrosesan data, pemodelan, hingga pengujian diimplementasikan menggunakan bahasa pemrograman Python.
4. Data yang diolah dalam penelitian ini terbatas pada atribut-atribut berbentuk numerik yang tersedia di dalam dataset.
5. Evaluasi performa model dibatasi pada pengukuran metrik Accuracy (Akurasi), Precision (Presisi), Recall, F1-Score, Area Under the Precision-Recall Curve (AUCPR), dan ROC-AUC (Receiver Operating Characteristic - Area Under Curve), serta representasi melalui Confusion Matrix.

1.4 Tujuan Penelitian

Adapun tujuan yang ingin dicapai melalui pelaksanaan penelitian ini adalah:

1. Membangun dan mengimplementasikan model algoritma *Isolation Forest* pada dataset transaksi kartu kredit.
2. Mengidentifikasi dan memisahkan transaksi kartu kredit yang termasuk ke dalam kategori anomali (*fraud*) dari transaksi normal.
3. Mengevaluasi serta menganalisis performa dari model deteksi anomali yang telah dibangun berdasarkan metrik evaluasi yang ditentukan.

1.5 Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan kontribusi dan manfaat bagi berbagai pihak, antara lain:

1. Manfaat Akademik Penelitian ini diharapkan dapat menambah khazanah ilmu pengetahuan, referensi ilmiah, serta literatur mengenai penerapan teknologi *Machine Learning*, khususnya dalam pemanfaatan metode *Unsupervised Learning* untuk studi kasus deteksi anomali.
2. Manfaat Bagi Peneliti Memberikan pemahaman yang lebih mendalam bagi peneliti mengenai mekanisme kerja algoritma *Isolation Forest*, serta mengasah kemampuan dalam melakukan prapemrosesan data dan mengevaluasi model pada dataset yang memiliki ketimpangan kelas (*imbalanced data*) secara ekstrem.
3. Manfaat Bagi Industri Memberikan gambaran praktis, referensi, serta rekomendasi bagi industri finansial atau perbankan mengenai potensi pemanfaatan sistem otomatis berbasis *Machine Learning* untuk mendeteksi tindakan *fraud*, sehingga dapat meminimalkan risiko kerugian finansial di masa mendatang.

1.6 Metode Penelitian

Metode penelitian ini dijalankan secara sistematis melalui beberapa tahapan berbasis kerangka kerja eksperimen data sains (*Data Science Lifecycle*) untuk memastikan pencapaian tujuan penelitian yang valid. Tahapan-tahapan tersebut meliputi:

1. Pengumpulan Data (*Data Collection*) Tahap awal penelitian dilakukan dengan mengunduh dataset sekunder *Credit Card Fraud Detection* dari platform Kaggle. Data ini memuat rekam jejak transaksi kartu kredit yang telah disamarkan demi privasi pengguna.
2. Prapemrosesan Data (*Data Preprocessing*) Data yang telah diperoleh kemudian dibersihkan dan dipersiapkan. Proses ini meliputi pemeriksaan nilai yang hilang (*missing*

- values*), seleksi atribut numerik yang relevan, serta standarisasi atau normalisasi skala data jika diperlukan agar dapat diproses secara optimal oleh algoritma.
3. Perancangan dan Pemodelan (*Model Development*) Melakukan konfigurasi dan implementasi algoritma *Isolation Forest* menggunakan bahasa pemrograman Python (melalui *library* seperti scikit-learn). Pada tahap ini dilakukan penyesuaian parameter penting, salah satunya adalah parameter kontaminasi (*contamination*) yang menentukan estimasi proporsi anomali dalam dataset.
 4. Pengujian dan Evaluasi Model (*Testing & Evaluation*) Model yang telah dilatih kemudian diuji untuk mendeteksi transaksi anomali. Hasil prediksi dari model *Isolation Forest* akan dibandingkan dengan label asli dari dataset menggunakan *Confusion Matrix*. Performa model selanjutnya diukur secara kuantitatif melalui nilai Accuracy, Precision, Recall, F1-Score, Area Under the Precision-Recall Curve (AUCPR), dan ROC-AUC sebagai metrik pembandingan.
 5. Analisis Hasil dan Penarikan Kesimpulan Tahap akhir berupa analisis mendalam terhadap hasil evaluasi performa model. Peneliti akan menginterpretasikan sejauh mana efektivitas *Isolation Forest* dalam menangani ketimpangan data transaksi, yang kemudian dirangkum menjadi kesimpulan penelitian.

1.7 Sistematika Penulisan

Untuk memberikan gambaran menyeluruh dan memudahkan pemahaman, laporan penelitian ini disusun menjadi lima bab dengan sistematika sebagai berikut:

- BAB 1: PENDAHULUAN

Bab ini berisi latar belakang masalah mengenai urgensi deteksi *fraud* kartu kredit, rumusan masalah, batasan masalah dalam penelitian, tujuan dan manfaat yang ingin dicapai, metode penelitian yang digunakan, serta sistematika penulisan laporan.

- BAB 2: LANDASAN TEORI

Bab ini memuat teori-teori dasar dan literatur relevan yang mendukung penelitian, meliputi konsep transaksi digital dan *fraud*, definisi *Machine Learning*, pendekatan *Unsupervised Learning*, mekanisme kerja algoritma *Isolation Forest*, bahasa pemrograman Python, serta teori mengenai metrik evaluasi seperti *Confusion Matrix*.

- BAB 3: METODOLOGI PENELITIAN

Bab ini menjelaskan secara rinci mengenai alur dan rancangan penelitian yang dilakukan. Di dalamnya dibahas mengenai deskripsi dataset yang digunakan, tahapan prapemrosesan data, skenario pemodelan algoritma *Isolation Forest*, hingga skema evaluasi yang diterapkan.

- BAB 4: HASIL DAN PEMBAHASAN

Bab ini menyajikan data hasil eksperimen, implementasi kode Python, dan visualisasi performa model. Di bagian ini juga dilakukan pembahasan mendalam mengenai efektivitas algoritma dalam mengidentifikasi anomali serta analisis terhadap nilai akurasi, presisi, *recall*, dan *f1-score* yang diperoleh.

- BAB 5: KESIMPULAN DAN SARAN

Bab ini berisi kesimpulan akhir yang ditarik dari seluruh hasil penelitian dan pembahasan guna menjawab rumusan masalah. Selain itu, bab ini juga memuat saran-saran akademis maupun praktis untuk pengembangan penelitian selanjutnya di masa depan.

BAB 2

TINJAUAN PUSTAKA

2.1 Penelitian Terdahulu

Penelitian terdahulu memiliki peran penting sebagai acuan, pijakan dasar, dan bahan perbandingan untuk mengetahui posisi kebaruan (*novelty*) dari penelitian yang dilakukan. Dalam konteks deteksi anomali pada transaksi kartu kredit, algoritma *unsupervised learning* seperti *Isolation Forest* menjadi salah satu metode yang paling intensif diteliti karena karakteristik data transaksi finansial yang umumnya sangat tidak seimbang (*highly imbalanced dataset*). Beberapa penelitian relevan yang melandasi penulisan skripsi ini dipaparkan sebagai berikut.

Penelitian terbaru oleh Zayer et al. (2026) yang berjudul "*Outlier Detection in Credit Card Transactions Using Isolation Forest and PCA*" mengusulkan sebuah arsitektur hibrida untuk mendeteksi kecurangan. Mereka mengombinasikan *Principal Component Analysis* (PCA) untuk reduksi dimensi fitur dan algoritma *Isolation Forest* untuk mengisolasi anomali. Menggunakan dataset kartu kredit Kaggle berisi 284.807 transaksi, penelitian tersebut berhasil mereduksi 30 fitur asli menjadi 12 komponen utama yang mampu menangkap 95% varians data. Hasil pengujian menunjukkan bahwa kombinasi ini sangat efisien dalam mempercepat waktu komputasi pemrosesan data berskala besar.

Selanjutnya, Waspada et al. (2020). dalam penelitiannya yang berjudul "*Performance Analysis of Isolation Forest Algorithm in Fraud Detection of Credit Card Transactions*" menyoroti bias metrik evaluasi pada dataset yang tidak seimbang. Mereka melakukan analisis mendalam terhadap algoritma *Isolation Forest* menggunakan metrik *Receiver Operating Characteristic - Area Under Curve* (ROC-AUC) dan *Area Under the Precision-Recall Curve* (AUCPR). Hasil penelitian menunjukkan bahwa nilai ROC-AUC yang tinggi tidak menjamin keandalan model dalam mendeteksi kecurangan riil, sehingga penggunaan AUCPR direkomendasikan sebagai metrik evaluasi yang lebih informatif untuk mengukur kinerja deteksi anomali tak terbimbing.

Ounacer et al. (2018) melalui publikasi ilmiah berjudul "*Using Isolation Forest in anomaly detection: the case of credit card transactions*" melakukan studi komparatif antara *Isolation Forest* dengan metode *unsupervised* tradisional lainnya, seperti *Local Outlier Factor* (LOF), *One-Class Support Vector Machine* (OCSVM), dan *K-Means*. Hasil eksperimen mereka membuktikan bahwa *Isolation Forest* memiliki keunggulan performa yang signifikan dibandingkan LOF dan OCSVM, baik dari segi akurasi deteksi maupun efisiensi penggunaan memori ketika menangani jutaan baris data transaksi e-commerce.

Penerapan *Isolation Forest* secara spesifik pada data skala besar juga diperkuat oleh Vandana et al. (2023) dalam artikel "*Fraud Detection using Isolation Forest Algorithm in Credit Card*". Penelitian ini menegaskan bahwa metode audit manual dan aturan konvensional (*rule-based*) sudah tidak lagi relevan bagi institusi perbankan modern karena kompleksitas pola kecurangan yang terus berubah. Algoritma *Isolation Forest* terbukti mampu mendeteksi anomali-anomali kecil (*minute anomalies*) yang tersembunyi di dalam repositori data perbankan berdimensi tinggi secara otomatis tanpa memerlukan label historis kecurangan.

Sebagai pelengkap teori fundamental, Cherif et al. (2020) dalam "*Credit card fraud detection in the era of disruptive technologies: A systematic review*" serta Rai dan Jagadeesha (2023) dalam "*Credit Card Fraud Detection using Machine Learning and Data Mining Techniques - a Literature Survey*" menyajikan ulasan literatur yang komprehensif dari ratusan publikasi ilmiah global. Kedua studi literatur tersebut menyimpulkan bahwa meskipun teknik *supervised learning* dan *deep learning* memiliki tingkat akurasi yang tinggi, model tersebut sangat rentan terhadap *overfitting* akibat ketimpangan kelas (*class imbalance*) yang ekstrem. Oleh karena itu, pendekatan *unsupervised* seperti *Isolation Forest* dinilai sebagai solusi paling adaptif dalam mendeteksi serangan fraud model baru yang belum pernah teridentifikasi sebelumnya.

Untuk mempermudah pemetaan dan melihat perbedaan posisi penelitian, ringkasan dari studi terdahulu beserta hubungannya dengan penelitian usulan disajikan pada Tabel 2.1 berikut.

Tabel 2.1 Ringkasan Penelitian Terdahulu

No	Penelitian Terdahulu	Kekurangan	Usulan
1	Waspada et al. (2020) <i>Performance Analysis of Isolation Forest Algorithm in Fraud Detection of Credit Card Transactions</i>	Hanya berfokus pada analisis teoritis perbandingan metrik evaluasi (ROC-AUC vs AUCPR) tanpa mengimplementasikan standarisasi skala data atau otomatisasi manajemen <i>file</i> hasil eksperimen.	Mengadopsi prinsip evaluasi yang objektif dengan menambahkan tahapan prapemrosesan berupa standarisasi skala data menggunakan <i>StandardScaler</i> serta melakukan ekstraksi otomatis terhadap 3 fitur paling berpengaruh (<i>top features</i>).
2	Cherif et al. (2020) <i>Systematic Review & Literature Survey on Credit</i>	Merupakan studi literatur sekunder (SLR) yang bersifat teoretis global, sehingga tidak menyajikan pengujian	Merealisasikan rekomendasi dari studi literatur global tersebut dalam bentuk eksperimen terprogram menggunakan data riil berskala besar (283.726 baris

	<i>Card Fraud Detection using Machine Learning</i>	praktis, implementasi baris kode, ataupun analisis performa langsung pada dataset spesifik.	pasca-pembersihan) untuk menguji keandalan <i>Isolation Forest</i> .
3	Zayer et al. (2026) <i>Outlier Detection in Credit Card Transactions Using Isolation Forest and PCA</i>	Terlalu fokus pada reduksi dimensi agresif dengan PCA (memangkas 30 fitur menjadi 12), sehingga berisiko menghilangkan varians informasi penting dari nilai transaksi asli serta mengabaikan pembersihan data duplikat.	Mempertahankan keaslian 29 fitur numerik murni untuk menjaga sensitivitas algoritma, namun mengoptimalkan kualitas data lewat <i>Data Quality Check</i> yang ketat dengan mengeliminasi 1.081 baris data duplikat riil.
4	Vandana et al. (2023) <i>Fraud Detection using Isolation Forest Algorithm in Credit Card</i>	Pembahasan algoritma masih bersifat konseptual umum dan arsitektur kode programnya belum terstruktur dengan baik untuk kebutuhan dokumentasi atau keterulangan eksperimen (<i>reproducibility</i>).	Menerapkan struktur pemrograman berbasis Python yang rapi dan terotomatisasi, di mana seluruh luaran eksperimen langsung diekspor ke repositori folder terstruktur (output/images, output/model, output/reports).
5	Ounacer et al. (2018) <i>Using Isolation Forest in anomaly detection: the case of credit card transactions</i>	Fokus penelitian terlalu luas pada komparasi lintas algoritma <i>unsupervised</i> (LOF, OCSVM, K-Means), sehingga tidak mengeksplorasi langkah pembersihan data yang spesifik untuk optimalisasi satu model.	Melakukan optimasi mendalam (<i>end-to-end</i>) khusus pada algoritma <i>Isolation Forest</i> melalui pembersihan data sekunder secara presisi, serta mengeklusi atribut non-kontributif seperti indeks waktu (Time) dan label kelas (Class) sebelum pelatihan.

Berdasarkan kajian terhadap penelitian-penelitian terdahulu di atas, posisi penelitian usulan dalam skripsi ini adalah menerapkan algoritma *Isolation Forest* murni dengan menekankan pada aspek prapemrosesan data (*Data Preprocessing*) yang disiplin. Langkah kritis yang membedakan penelitian ini adalah pelaksanaan *Data Quality Check* yang ketat (eliminasi data duplikat secara presisi), eksklusi atribut non-numerik/indeks, standarisasi skala menggunakan *StandardScaler*, serta otomatisasi penyimpanan laporan performa dan visualisasi model ke dalam direktori terstruktur demi mendukung prinsip keterulangan eksperimen (*reproducibility*).

2.2 Landasan Teori

Sub-bab ini menguraikan berbagai landasan teoretis, konsep dasar, serta literatur akademik yang menjadi pijakan utama dalam pelaksanaan dan penyelesaian permasalahan pada penelitian ini. Pemaparan teori difokuskan pada konsep-konsep pokok yang relevan dengan ruang lingkup pemodelan, mulai dari fundamental *data engineering* dan prapemrosesan data, karakteristik kejahatan finansial, konsep dasar deteksi anomali (*anomaly detection*), hingga penjabaran matematis terkait algoritma *Isolation Forest* dan metrik evaluasi yang digunakan.

2.2.1 Data Engineering dan Prapemrosesan Data

Data Engineering merupakan suatu rumpun praktik yang berfokus pada pengembangan, implementasi, dan pemeliharaan arsitektur atau sistem yang berfungsi untuk mengumpulkan, mengelola, serta mengubah data mentah menjadi informasi yang siap digunakan untuk analisis tingkat lanjut atau pemodelan *machine learning*. Salah satu tahapan paling krusial di dalam siklus *data engineering* adalah prapemrosesan data (*data preprocessing*).

Prapemrosesan data bertujuan untuk membersihkan dan mentransformasikan data mentah yang sering kali memiliki gangguan (*noisy*), inkonsisten, mengandung pencilan, atau mengalami redundansi. Tahapan dasar dalam prapemrosesan data finansial meliputi:

1. **Pemeriksaan Kualitas Data (*Data Quality Check*):** Proses evaluasi awal untuk mendeteksi anomali struktural pada dataset, seperti adanya nilai yang hilang (*missing values*) atau tipe data yang tidak sesuai.
2. **Penanganan Data Duplikat (*Duplicate Elimination*):** Penghapusan baris data yang identik secara keseluruhan. Keberadaan data duplikat dalam jumlah besar dapat menyebabkan bias pada model estimasi kepadatan atau pembentukan struktur pohon, karena model akan mempelajari pola yang sama secara berulang secara tidak proporsional.
3. **Seleksi Fitur (*Feature Selection*):** Proses mengisolasi atau mengeklusi variabel-variabel yang tidak memberikan kontribusi informasi terhadap target deteksi (misalnya variabel indeks, deret waktu linier, atau label eksternal) untuk meminimalkan kompleksitas komputasi.

2.2.2 Deteksi Anomali (*Anomaly Detection*)

Deteksi anomali, yang juga dikenal sebagai pencilan (*outlier detection*), adalah sebuah teknik dalam penambangan data (*data mining*) dan *machine learning* yang bertujuan untuk mengidentifikasi pola, objek, atau peristiwa dalam dataset yang tidak sesuai dengan perilaku normal yang diharapkan.

Secara umum, terdapat tiga pendekatan utama dalam deteksi anomali berdasarkan ketersediaan label pada dataset:

1. Supervised Anomaly Detection:

Model dilatih menggunakan dataset yang seluruh sampelnya telah diberi label secara eksplisit (normal atau anomali). Pendekatan ini memiliki kendala besar apabila terjadi ketimpangan kelas yang ekstrem.

2. Semi-Supervised Anomaly Detection:

Model dilatih hanya menggunakan sampel dari kelas normal untuk mempelajari batas perilaku normal, kemudian mengklasifikasikan sampel yang berada di luar batas tersebut sebagai anomali.

3. Unsupervised Anomaly Detection:

Model beroperasi tanpa membutuhkan label historis sama sekali. Pendekatan ini murni mengandalkan karakteristik intrinsik data, seperti jarak, kepadatan, atau isolasi struktural, dengan asumsi dasar bahwa instans normal berjumlah sangat dominan sedangkan instans anomali berjumlah sangat sedikit dan memiliki perbedaan fitur yang ekstrem.

2.2.3 Kecurangan Kartu Kredit (Credit Card Fraud)

Kecurangan kartu kredit merupakan salah satu bentuk kejahatan finansial di mana pihak yang tidak berwenang melakukan transaksi keuangan menggunakan akun atau kartu kredit orang lain tanpa izin. Karakteristik utama dari dataset transaksi kartu kredit dalam dunia nyata adalah tingkat ketimpangan kelas (*class imbalance*) yang sangat ekstrem, di mana jumlah transaksi legal jauh mendominasi (sering kali melebihi 99.5%), sedangkan transaksi kecurangan berkisar di bawah 0.5%.

Ketimpangan kelas yang ekstrem ini menimbulkan tantangan besar bagi algoritma klasifikasi konvensional, karena model cenderung mengalami *overfitting* pada kelas mayoritas (transaksi normal) dan gagal mengenali pola kelas minoritas (transaksi fraud). Oleh karena itu, penerapan metode *unsupervised* yang berfokus pada sifat kelangkaan instans fraud menjadi pendekatan yang lebih adaptif dan andal.

2.2.4 Principal Component Analysis (PCA)

Principal Component Analysis (PCA) adalah teknik statistika multivariat yang digunakan untuk reduksi dimensi (*dimensionality reduction*) dengan tetap mempertahankan sebagian besar varians informasi dari dataset asli. PCA mentransformasikan sekumpulan variabel yang saling berkorelasi menjadi sekumpulan variabel baru yang tidak saling berkorelasi linier, yang disebut sebagai Komponen Utama (*Principal Components*).

Di dalam manajemen data finansial yang sensitif, transformasi PCA sering kali diterapkan oleh penyedia data untuk menjaga privasi pengguna (*user anonymity*). Atribut asli seperti detail transaksi, lokasi, dan identitas pengguna dikonversi menjadi fitur numerik abstrak (misalnya komponen $V_1, V_2, \dots, V_N$) melalui proyeksi orthogonal ke dalam ruang berdimensi lebih rendah.

2.2.5 Standardisasi Skala Data (StandardScaler)

Banyak algoritma *machine learning* yang kinerjanya sangat sensitif terhadap perbedaan skala atau satuan antarfitur. Proses standardisasi mengubah distribusi fitur sehingga memiliki nilai rata-rata (*mean*) sama dengan nol dan simpangan baku (*standard deviation*) sama dengan satu. Prosedur ini diimplementasikan melalui transformasi skor-Z (*Z-score normalization*), dengan model matematis sebagai berikut:

$$z = \frac{x - \mu}{\sigma}$$

Keterangan:

z = nilai fitur setelah ditransformasi (skor-Z)

x = nilai fitur asli sebelum ditransformasi

μ = rata-rata (*mean*) dari fitur tersebut

σ = simpangan baku (*standard deviation*) dari fitur tersebut

Melalui standardisasi ini, fitur dengan rentang nilai yang besar (seperti nominal transaksi atau Amount) tidak akan mendominasi perhitungan fitur berdimensi kecil lainnya dalam ruang metrik algoritma.

2.2.6 Algoritma Isolation Forest

Algoritma Isolation Forest yang diperkenalkan oleh Liu, Ting, dan Zhou (2008) merupakan metode unsupervised learning yang secara khusus didesain untuk mengisolasi anomali secara langsung, alih-alih membangun profil data normal berdasarkan jarak atau

kepadatan data. Fondasi dasar algoritma ini didasarkan pada dua sifat utama dari data anomali: (1) berjumlah sedikit (*few*), dan (2) memiliki atribut yang sangat berbeda dari data normal (*different*).

a. Mekanisme Kloning Pohon (*Isolation Trees / iTree*)

Proses isolasi dilakukan dengan membangun sekumpulan pohon biner acak (*ensemble of iTrees*). Pada setiap simpul (*node*) di dalam *iTree*, sebuah fitur dipilih secara acak dari ruang fitur yang tersedia, kemudian sebuah nilai pemisah (*split value*) ditentukan secara acak di antara nilai minimum dan maksimum dari fitur terpilih tersebut. Proses partisi rekursif ini diilustrasikan sebagai skema pemotongan ruang data.

Karena sifat fiturnya yang tidak lazim, instans data yang bersifat anomali memerlukan jauh lebih sedikit partisi acak untuk terisolasi pada simpul daun (*leaf node*) terluar jika dibandingkan dengan instans data normal yang cenderung berkerumun rapat.

b. Panjang Jalur (*Path Length*)

Secara matematis, tingkat kemudahan suatu instans data x untuk diisolasi diukur menggunakan fungsi panjang jalur $h(x)$. Panjang jalur $h(x)$ adalah jumlah tepi (*edges*) yang dilewati oleh instans x dari simpul akar (*root node*) hingga mencapai simpul terminasi pada sebuah *iTree*.

Untuk melakukan normalisasi terhadap ukuran sampel data, digunakan fungsi rata-rata panjang jalur dari pohon pencarian biner gagal (*unsuccessful search in Binary Search Tree / BST*) sebagai representasi dasar komparasi bagi sampel berukuran n :

$$c(n) = 2 \ln(n - 1) + 0.5772156649 - \frac{2(n - 1)}{n}$$

Keterangan:

- n = jumlah sampel data instans
- 0.5772156649 = Konstanta Euler-Mascheroni

c. Skor Anomali (Anomaly Score)

Skor anomali s untuk suatu sampel instans x dihitung dengan mengombinasikan ekspektasi panjang jalur $E(h(x))$ dari seluruh koleksi *iTrees* menggunakan formulasi eksponensial berikut:

$$s(x, n) = 2^{-\frac{E(h(x))}{c(n)}}$$

Keterangan nilai skor anomali s :

- Jika skor s mendekati nilai 1, maka panjang jalur sangat pendek, sehingga instans x dipastikan sebagai anomali.
- Jika skor s jauh lebih kecil dari 0.5, maka instans x berada jauh di kedalaman pohon, mengindikasikan bahwa instans tersebut adalah data normal.
- Jika seluruh sampel mengembalikan nilai $s \approx 0.5$, maka keseluruhan dataset dianggap tidak memiliki anomali yang jelas.

2.2.7 Metrik Evaluasi Deteksi Anomali Finansial

Mengingat ketidakseimbangan kelas yang ekstrem pada domain *fraud detection*, metrik evaluasi akurasi standar (*Accuracy*) tidak dapat dijadikan acuan utama karena hasil interpretasinya bias. Model dievaluasi menggunakan komponen *Confusion Matrix* yang menghasilkan metrik turunan berupa:

- Precision: Rasio ketepatan model dalam memprediksi transaksi fraud dari keseluruhan transaksi yang dituduh fraud oleh model.

$$\text{Precision} = \frac{\text{True Positive (TP)}}{\text{True Positive (TP)} + \text{False Positive (FP)}}$$

- Recall (Sensitivity): Rasio kemampuan model dalam menangkap seluruh transaksi fraud riil yang terjadi di lapangan.

$$\text{Recall} = \frac{\text{True Positive (TP)}}{\text{True Positive (TP)} + \text{False Negative (FN)}}$$

Area Under the Precision-Recall Curve (AUCPR): Grafik hubungan kurva antara *Precision* dan *Recall*. Metrik AUCPR dinilai jauh lebih valid dan objektif dibandingkan ROC-AUC ketika mengevaluasi kinerja *Isolation Forest* pada dataset finansial *imbalanced*, karena AUCPR memberikan bobot penalti yang lebih besar terhadap kemunculan *False Positive* pada kelas minoritas.

BAB 3

METODOLOGI PENELITIAN

3.1 Kerangka Berpikir

Penelitian ini disusun berdasarkan kerangka berpikir yang menggambarkan alur proses secara menyeluruh, mulai dari tahap input data, proses pengolahan dan pemodelan, hingga output yang dihasilkan. Kerangka berpikir ini digambarkan dalam bentuk diagram swimlane dengan tiga kolom utama, yaitu *Input*, *Proses*, dan *Output*, sebagaimana ditunjukkan pada Gambar 3.1.

Pada tahap Input, penelitian ini menggunakan dataset transaksi kartu kredit yang bersumber dari Kaggle (*Credit Card Fraud Detection Dataset*), yang terdiri dari 284.807 baris transaksi dengan 31 atribut, termasuk 28 fitur hasil transformasi *Principal Component Analysis* (V1–V28), atribut *Time*, *Amount*, serta label *Class* yang menandakan status transaksi normal atau *fraud*.


Pada tahap Proses, data mentah tersebut melalui serangkaian tahapan yang terdiri dari:

1. *Data Quality Check* untuk mendeteksi nilai duplikat dan nilai kosong (*missing value*);
2. *Data Cleaning* berupa eliminasi data duplikat;
3. *Feature Selection*, yaitu pemilihan atribut numerik murni (V1–V28 dan *Amount*) dengan mengeluarkan atribut *Time* dan *Class* dari proses pelatihan model;
4. *Standardization* menggunakan *StandardScaler* untuk menyamakan skala antar fitur;
5. pelatihan model deteksi anomali menggunakan algoritma *Isolation Forest*; serta
6. evaluasi performa model menggunakan *Confusion Matrix* dan metrik evaluasi pendukung.

Pada tahap Output, penelitian ini menghasilkan:

1. model *Isolation Forest* yang mampu mengklasifikasikan transaksi ke dalam kategori normal atau anomali (*fraud*);
2. skor anomali (*anomaly score*) untuk setiap transaksi; serta
3. hasil evaluasi performa model yang disajikan dalam bentuk *Confusion Matrix*, nilai *Accuracy*, *Precision*, *Recall*, *F1-Score*, dan *Area Under the Precision-Recall Curve* (AUCPR).

Secara keseluruhan, kerangka berpikir ini menggambarkan bagaimana penelitian ini berupaya menjawab permasalahan yang telah dirumuskan pada Bab 1, yaitu membangun model deteksi anomali yang mampu mengidentifikasi transaksi *fraud* secara efektif pada dataset yang bersifat *imbalanced*, serta mengevaluasi kinerjanya secara objektif menggunakan metrik yang sesuai dengan karakteristik data tersebut.




Gambar 3.1 Kerangka Berpikir Penelitian

3.2 Pengumpulan dan Pengolahan Data

Pada tahapan ini, diuraikan seluruh alur kerja yang dilalui oleh dataset mentah, mulai dari tahap akuisisi hingga transformasi menjadi matriks fitur bersih yang siap dipelajari oleh model *Isolation Forest*. Alur kerja ini dirancang untuk menjawab tantangan utama penelitian yang telah diuraikan pada Bab 1, yaitu mendeteksi anomali pada data finansial yang berdimensi tinggi (*high-dimensional*) serta memiliki ketimpangan kelas yang sangat ekstrem (*extreme class imbalance*).

Seluruh tahapan prapemrosesan dieksekusi secara terprogram menggunakan bahasa Python dengan memanfaatkan pustaka `pandas` dan `scikit-learn`. Secara konseptual dan teknis, tahapan pengumpulan dan pengolahan data pada penelitian ini digambarkan melalui diagram alur (*flowchart*) berikut:



Gambar 3.2 Diagram Alur Pengumpulan dan Pengolahan data

3.3 Pengumpulan Data

Pengumpulan data dilakukan melalui metode akuisisi dataset sekunder yang diperoleh secara resmi dari repositori publik Kaggle dengan nama file `creditcard.csv`. Dataset ini memuat rekam jejak historis transaksi kartu kredit yang dilakukan oleh nasabah di Eropa selama dua hari pada bulan September 2013.

Pada saat dimuat ke dalam *dataframe* (`df_raw`), dataset ini memiliki dimensi riil sebesar 284.807 baris transaksi (instans) dan 31 kolom atribut. Rincian dari 31 atribut tersebut adalah sebagai berikut:

1. Fitur Waktu (`Time`, `float64`): Mencatat jumlah detik yang berlalu antara setiap transaksi dengan transaksi pertama di dalam dataset. Rentang nilai dimulai dari 0,00 hingga 172.792,00 detik.
2. Fitur Proyeksi Ortogonal (`V1` hingga `V28`, `float64`): Merupakan 28 fitur numerik hasil transformasi *Principal Component Analysis* (PCA). Penyedia asal dataset melakukan transformasi ini guna menjaga kerahasiaan (*anonymity*) nasabah serta mematuhi regulasi privasi data perbankan, sehingga identitas pengguna, lokasi, maupun jenis barang yang ditransaksikan tidak dapat dilacak secara langsung.

3. Fitur Nominal Transaksi (`Amount`, `float64`): Merepresentasikan nilai besaran finansial dari transaksi yang terjadi. Berdasarkan output statistik deskriptif pada sistem, atribut ini memiliki nilai minimum 0,00 dan nilai maksimum yang sangat ekstrem mencapai 25.691,16.
4. Fitur Ground Truth (`Class`, `int64`): Merupakan variabel biner penanda kelas transaksi riil, di mana nilai 0 merepresentasikan transaksi normal, dan riil 1 merepresentasikan kejahatan atau kecurangan (*fraud*).

Menyambung rumusan masalah pada Bab 1, dataset ini memiliki karakteristik ketimpangan kelas yang sangat tajam (*imbalanced dataset*). Dari total populasi 284.807 baris data, jumlah transaksi kecurangan (`Class == 1`) hanya berjumlah 492 instans (0,17%), sedangkan sisanya didominasi oleh transaksi normal yang sah.

3.3.1 Pengolahan Data

Mengingat algoritma *Isolation Forest* yang mendasari penelitian di Bab 2 bekerja dengan membelah ruang fitur secara rekursif (*random partitioning*), keberadaan data berderau (*noise*), duplikasi yang masif, serta perbedaan skala metrik antar-fitur dapat merusak perhitungan skor anomali. Oleh karena itu, matriks input mentah `df_raw` diproses melalui empat tahapan komputasi sebagai berikut:

1. Pemeriksaan Kualitas Data (*Data Quality Check*) Pada tahap awal, sistem melakukan inspeksi integritas struktur data. Hasil pengecekan menunjukkan dua temuan utama:
 - Missing Values: Hasil identifikasi melalui fungsi `df_raw.isnull().sum()` menunjukkan bahwa seluruh 31 kolom memiliki nilai kosong sebesar 0 (0,0%), yang berarti dataset mentah memiliki kelengkapan pencatatan murni.
 - Duplicate Rows: Melalui fungsi `df_raw.duplicated().sum()`, sistem mendeteksi adanya 1.081 baris transaksi duplikat murni.
2. Pembersihan Data (*Data Cleaning*) Berdasarkan temuan audit kualitas data, pembersihan dilakukan secara terprogram menggunakan objek salinan `df = df_raw.copy()`:
 - Deduplikasi: Baris duplikat sebanyak 1.081 instans dieleminasi secara permanen melalui instruksi `df.drop_duplicates(inplace=True)`. Proses ini mereduksi total instans populasi dari 284.807 baris menjadi 283.726 baris bersih. Dalam konteks *Isolation Forest*, penghapusan duplikat sangat penting karena baris yang identik akan menciptakan kepadatan semu (*artificial density*) yang mempersulit pohon biner dalam mengisolasi pencilan.
 - Imputasi Defensif: Walaupun dataset tidak memiliki *missing value* murni, sistem tetap mengimplementasikan logika penanganan otomatis `df_`

`num[col].fillna(median_val, inplace=True)` yang mengisi kekosongan dengan nilai tengah (*median*). Hal ini dirancang agar *pipeline* pemrosesan tetap kokoh (*robust*) saat menerima data transaksi baru di masa depan.

3. Seleksi Fitur (*Feature Selection*) Mengingat *Isolation Forest* pada Bab 2 diimplementasikan sebagai pendekatan *Unsupervised Learning* (tanpa supervisi label), model harus mempelajari struktur data semata-mata dari varians fitur. Oleh karena itu, dilakukan pemisahan atribut secara tegas:

- Eksklusi Kolom (`EXCLUDE_COLS = ['Class', 'Time']`): Kolom `Class` dan `Time` dibuang dari matriks fitur. Atribut `Class` dieksklusikan untuk menghindari kebocoran informasi (*data leakage*) agar algoritma murni mencari pencilan tanpa mengintip kunci jawaban historis. Atribut `Time` dibuang karena penambahan urutan detik linier tidak memiliki korelasi sebab-akibat terhadap probabilitas terjadinya *fraud*.
- Fitur Pelatihan (*X*): Atribut yang dipertahankan sebagai matriks input pelatihan (`num_cols`) murni berjumlah 29 atribut numerik, yang mencakup fitur `V1` hingga `V28` ditambah kolom `Amount`.

4. Transformasi Skala Data (*Feature Scaling*) Fitur-fitur hasil transformasi PCA (`V1-V28`) memiliki sebaran metrik yang terpusat di angka kecil dekat nol, sementara atribut `Amount` memuat besaran nominal transaksi murni yang melebar jauh hingga nilai maksimum 25.691,16. Jika matriks ini langsung dilatihkan, fitur `Amount` akan mendominasi dan mengacaukan penentuan titik potong (*split point*) pada simpul pohon acak. Untuk menetralkan ketimpangan metrik tersebut, seluruh 29 fitur dinormalisasi menggunakan teknik *Z-score normalization* melalui pustaka `StandardScaler()`. Transformasi ini dieksekusi melalui perintah:

```
scaler = StandardScaler()
X_scaled = scaler.fit_transform(df_num)
```

Listing 3.1 Implementasi `StandardScaler` pada Matriks Fitur

Secara matematis, standardisasi ini mengubah setiap nilai fitur x menjadi skor- Z murni dengan formula:

$$z = \frac{x - \mu}{\sigma}$$

Di mana μ adalah rata-rata fitur, dan σ adalah simpangan baku fitur di dalam populasi.

Melalui transformasi ini, matriks fitur hasil pembersihan (*df_scaled*) memiliki distribusi yang seimbang di seluruh 29 kolomnya, dengan nilai rata-rata mendekati nol ($\mu \approx 0$) dan standar deviasi sebesar satu ($\sigma \approx 1$). Matriks berdimensi 283.726 baris $\times$ 29 kolom inilah yang selanjutnya dilemparkan ke dalam tahap pelatihan algoritma *Isolation Forest*.

3.4 Perancangan Teknik/Model (Kebaharuan)

Penelitian ini tidak sekadar mengulang implementasi algoritma *Isolation Forest* secara generik, melainkan menawarkan sebuah rancangan pipeline end-to-end yang memiliki kebaruan dari tiga dimensi sekaligus: kebaruan dari sisi pengolahan data, kebaruan dari sisi konfigurasi model, dan kebaruan dari sisi otomatisasi luaran eksperimen. Ketiga dimensi tersebut dirancang secara terintegrasi untuk menjawab celah-celah yang ditemukan pada penelitian-penelitian terdahulu sebagaimana telah dipetakan pada Tabel 2.1.

3.4.1 Kebaharuan dari Sisi Pengolahan Data

Sebagian besar penelitian terdahulu termasuk Zayer et al. (2026) dan Vandana et al. (2023) langsung melatih model pada dataset mentah tanpa melalui tahapan pemeriksaan kualitas data yang terstruktur. Penelitian ini memperkenalkan tahapan *Data Quality Check* yang bersifat wajib dan terprogram sebelum model dilatih. Pada tahapan ini, sistem secara otomatis mendeteksi dan mengeliminasi 1.081 baris data duplikat dari total 284.807 baris, menghasilkan dataset bersih sebesar 283.726 baris.

Langkah deduplikasi ini memiliki dampak langsung terhadap kualitas model. Dalam mekanisme *Isolation Forest*, data yang identik menciptakan kepadatan semu (*artificial density*) di dalam ruang fitur. Hal ini akan menyebabkan pohon biner acak (*iTree*) membutuhkan lebih banyak partisi untuk mengisolasi titik-titik data yang seharusnya ringan diisolasi, sehingga skor anomali yang dihasilkan menjadi tidak akurat. Dengan mengeliminasi duplikat, distribusi ruang fitur menjadi lebih representatif dan bersih, sehingga panjang jalur isolasi (*path length*) yang dihitung oleh model mencerminkan anomali yang sesungguhnya.

Selain itu, berbeda dengan Zayer et al. (2026) yang menerapkan reduksi dimensi agresif melalui PCA hingga memangkas 30 fitur menjadi hanya 12 komponen utama, penelitian ini secara sadar memilih untuk mempertahankan seluruh 29 fitur numerik murni (V1–V28 dan Amount). Keputusan ini dilandasi oleh pertimbangan bahwa setiap komponen PCA telah mengandung informasi gabungan dari fitur asli, sehingga reduksi lebih lanjut berisiko menghilangkan varians kecil namun kritis yang justru menjadi penanda transaksi fraud. Sebagai gantinya, penyamaan skala antarfitur dilakukan melalui standardisasi Z-score

menggunakan StandardScaler, sehingga fitur Amount yang memiliki rentang nilai ekstrem (0 hingga 25.691,16) tidak mendominasi penentuan titik potong pada simpul pohon acak.

3.4.2 Kebaharuan dari Sisi Konfigurasi Model

Model Isolation Forest dalam penelitian ini dikonfigurasi dengan parameter yang ditetapkan secara eksplisit dan berbasis data, bukan menggunakan nilai default perpustakaan. Terdapat dua parameter kritis yang menjadi fokus perancangan, yaitu:

a. **Parameter *contamination*:**

Parameter ini menentukan estimasi proporsi anomali yang diharapkan ada di dalam dataset. Berbeda dengan beberapa penelitian terdahulu yang menggunakan nilai default ('auto') atau nilai arbitrer, penelitian ini menghitung nilai kontaminasi secara otomatis dan dinamis langsung dari distribusi ground truth dataset melalui formula:

```
contamination_rate = df["Class"].sum() / len(df)
```

Pendekatan ini menghasilkan nilai kontaminasi sebesar $\pm 0,0017$ (sekitar 0,17%), yang secara langsung mencerminkan proporsi fraud riil dalam dataset setelah pembersihan data. Dengan demikian, ambang batas keputusan (*decision threshold*) yang digunakan model bersifat sepenuhnya *data-driven*, bukan spekulatif.

b. **Parameter *n_estimators*:**

Penelitian ini menetapkan jumlah pohon isolasi sebesar 200, dua kali lipat dari nilai default scikit-learn (100). Penambahan jumlah pohon ini bertujuan untuk menstabilkan estimasi skor anomali, terutama pada dataset berskala besar seperti dataset yang digunakan (283.726 baris), sehingga variance antar-run dapat diminimalkan.

c. **Parameter *random_state*:**

Ditetapkan pada nilai tetap (*seed*) untuk memastikan hasil eksperimen bersifat deterministik dan dapat direproduksi (*reproducible*). Hal ini menjawab kelemahan yang ditemukan pada Vandana et al. (2023) di mana arsitektur kode eksperimen tidak dirancang untuk keterulangan hasil.

Dengan demikian, konfigurasi model yang diusulkan secara ringkas dapat diformulasikan sebagai berikut:

```
IsolationForest(  
    n_estimators=200, contamination=contamination_rate,  
    random_state=42  
)
```


Listing 3.2 Konfigurasi parameter Isolation Forest

3.4.3 Kebaharuan dari Sisi Otomatisasi Luaran Eksperimen

Aspek kebaruan ketiga yang membedakan penelitian ini dari Vandana et al. (2023) dan Ounacer et al. (2018) adalah penerapan sistem manajemen luaran eksperimen yang terstruktur dan terotomatisasi. Seluruh artefak hasil eksperimen mulai dari visualisasi, model terlatih, hingga laporan performa disimpan secara otomatis ke dalam direktori terorganisir, sebagai berikut:

- `output/images/`: menyimpan seluruh visualisasi hasil eksperimen, termasuk grafik distribusi skor anomali, confusion matrix heatmap, dan kurva Precision-Recall.
- `output/model/`: menyimpan objek model Isolation Forest yang telah dilatih dalam format serialisasi (`.pkl`), sehingga model dapat digunakan ulang tanpa perlu melatih ulang dari awal.
- `output/reports/`: menyimpan laporan performa model dalam format teks terstruktur, mencakup seluruh nilai metrik evaluasi (Accuracy, Precision, Recall, F1-Score, dan AUCPR) beserta identitas konfigurasi eksperimen.

Sistem penyimpanan luaran yang terstruktur ini secara langsung mendukung prinsip keterulangan eksperimen ilmiah (*reproducibility*) yang menjadi salah satu standar mutu utama dalam penelitian sains data modern.

3.4.4 Ringkasan Posisi Kebaharuan

Untuk mempermudah pemahaman posisi kebaruan penelitian ini dibandingkan dengan metode yang sudah ada, perbedaan rancangan dirangkum pada Tabel 3.1 berikut.

Tabel 3.1 Perbandingan Rancangan Model Penelitian Ini dengan Penelitian Terdahulu

Aspek	Penelitian Terdahulu	Penelitian Ini (Usulan)
Pemeriksaan Kualitas Data	Tidak dilakukan atau hanya sebatas pengecekan missing value	Data Quality Check wajib: deteksi & eliminasi 1.081 baris duplikat
Pengelolaan Dimensi Fitur	Reduksi PCA agresif (30 → 12 fitur) atau tanpa seleksi fitur	Mempertahankan 29 fitur numerik murni; penyamaan skala via StandardScaler
Penetapan Parameter Kontaminasi	Default library ('auto') atau nilai arbitrer	Dihitung otomatis dari ground truth data: $\frac{df["Class"].sum()}{len(df)} \approx 0,0017$

Aspek	Penelitian Terdahulu	Penelitian Ini (Usulan)
Keterulangan Eksperimen	Tidak dirancang secara eksplisit	random_state tetap + direktori output terstruktur otomatis
Metrik Evaluasi Utama	ROC-AUC atau akurasi umum	AUCPR sebagai metrik primer + Confusion Matrix lengkap

3.5 Evaluasi Teknik/Model (*Teknik Evaluasi*)

Evaluasi model dalam penelitian ini dirancang untuk mengukur kemampuan Isolation Forest mendeteksi transaksi fraud secara akurat pada kondisi dataset yang sangat tidak seimbang (*highly imbalanced*), di mana kelas fraud hanya mencakup sekitar 0,17% dari seluruh data. Oleh karena itu, pemilihan teknik dan metrik evaluasi dilakukan secara cermat agar tidak menghasilkan gambaran kinerja yang menyesatkan.

3.5.1 Prosedur Evaluasi

Karena Isolation Forest merupakan algoritma *unsupervised*, model dilatih tanpa menggunakan label kelas (Class) sama sekali. Label tersebut baru digunakan pada tahap evaluasi sebagai *ground truth* untuk mengukur seberapa akurat prediksi anomali model dibandingkan dengan kondisi fraud yang sesungguhnya.

Sebelum metrik dihitung, dilakukan dua konversi label terlebih dahulu agar polaritas antara output model dan ground truth sejajar:

1. Prediksi model yang bertipe 1 = normal dan -1 = anomali dikonversi menjadi skema biner yang sama dengan ground truth, yaitu 1 = fraud dan 0 = normal, melalui operasi:

```
y_pred_bin = np.where(y_pred == -1, 1, 0)
```

2. Skor anomali dari `decision_function` yang bersifat *semakin rendah = semakin anomali* dibalik tandanya agar berlaku sebaliknya — *semakin tinggi = semakin mirip fraud* — sehingga dapat digunakan pada metrik berbasis probabilitas seperti AUCPR:

```
y_score = -scores
```

3.5.2 Metrik Evaluasi

Penelitian ini menggunakan enam metrik evaluasi yang dihitung sekaligus, yaitu:

Tabel 3.2 Ringkasan Metrik Evaluasi Model

Metrik	Formula	Fokus Pengukuran	Peran
Accuracy	$(TP+TN) / (TP+TN+FP+FN)$	Proporsi prediksi benar secara keseluruhan	Sekunder
Precision	$TP / (TP+FP)$	Kualitas prediksi positif seberapa bersih hasil deteksi fraud	Sekunder
Recall	$TP / (TP+FN)$	Kelengkapan deteksi seberapa banyak fraud yang tidak terlewat	Sekunder
F1-Score	$2 \times (Precision \times Recall) / (Precision + Recall)$	Keseimbangan antara Precision dan Recall	Sekunder
ROC-AUC	Area under ROC Curve	Kemampuan diskriminasi model secara umum	Sekunder
AUCPR	Area under Precision-Recall Curve	Kemampuan model pada kelas minoritas (fraud)	Primer

1. **Accuracy**

Proporsi prediksi benar (baik normal maupun fraud) terhadap seluruh data. Metrik ini dilaporkan namun tidak dijadikan patokan utama, karena pada dataset yang sangat tidak seimbang, model yang memprediksi semua transaksi sebagai normal pun bisa menghasilkan akurasi di atas 99%.

2. **Precision**

Dari seluruh transaksi yang diprediksi sebagai fraud, berapa proporsi yang memang benar fraud. Metrik ini mengukur kualitas prediksi positif model.

3. **Recall**

Dari seluruh transaksi yang sesungguhnya fraud, berapa proporsi yang berhasil terdeteksi oleh model. Metrik ini mengukur kemampuan model dalam tidak melewatkan kasus fraud (*false negative*).

4. **F1-Score**

Rata-rata harmonik antara Precision dan Recall. Metrik ini berguna sebagai ukuran keseimbangan antara keduanya, terutama ketika terdapat trade-off di antara keduanya.

5. **AUCPR (Area Under the Precision-Recall Curve)**

Metrik ini menjadi metrik primer dalam penelitian ini. AUCPR dihitung menggunakan `average_precision_score` dari `scikit - learn`, yang mengintegrasikan kurva Precision-Recall di seluruh rentang ambang batas keputusan. Pada dataset yang sangat tidak seimbang, AUCPR jauh lebih representatif dibandingkan ROC-

AUC, karena ROC - AUC tetap terlihat tinggi meskipun model buruk dalam mendeteksi i kelas minoritas. AUCPR yang tinggi menandakan model mampu mempertahankan presisi yang baik bahkan ketika berusaha menangkap sebanyak mungkin kasus fraud.

6. ROC-AUC

Turut dihitung sebagai pembandingan, namun bukan sebagai metrik primer karena keterbatasannya pada kondisi dataset tidak seimbang sebagaimana dijelaskan di atas.

3.5.3 Visualisasi Evaluasi

Untuk memperjelas hasil evaluasi, penelitian ini menghasilkan dua visualisasi utama yang disimpan secara otomatis ke direktori `output/images/`:

1. **Confusion Matrix Heatmap** menampilkan distribusi TN, FP, FN, dan TP dalam format matriks berwarna sehingga pola kesalahan model dapat langsung dipahami secara visual.
2. **Kurva Precision-Recall** menampilkan hubungan antara Precision dan Recall di seluruh rentang ambang batas, dengan nilai AUCPR ditampilkan pada legenda. Area di bawah kurva diarsir untuk mempermudah perbandingan visual antar model jika dilakukan pada penelitian lanjutan.

3.5.4 Analisis Pentingnya Fitur

Sebagai pelengkap evaluasi, penelitian ini juga mengukur kontribusi masing-masing fitur terhadap skor anomali menggunakan pendekatan korelasi absolut antara nilai tiap fitur dengan `anomaly_score` yang dihasilkan model:

```
importance_vals = [  
    abs(np.corrcoef(df_num[col].values, scores)[0, 1]) for  
    col in num_cols  
]
```

Semakin tinggi nilai korelasi absolut suatu fitur, semakin besar pengaruhnya terhadap penentuan skor anomali. Hasil peringkat fitur ini disajikan dalam bentuk tabel dan diagram batang horizontal (*horizontal bar chart*), sehingga dapat diidentifikasi fitur mana yang paling dominan dalam membedakan transaksi normal dan transaksi fraud.

BAB 4

IMPLEMENTASI DAN EKSPERIMEN

Bab ini menyajikan seluruh tahapan implementasi dan eksperimen yang dilakukan dalam penelitian, mulai dari persiapan data, pelatihan model, hingga evaluasi dan analisis hasil. Implementasi dilaksanakan secara terprogram menggunakan bahasa Python dalam lingkungan Jupyter Notebook dengan memanfaatkan pustaka `pandas` 2.3.3, `numpy` 2.2.6, dan `scikit-learn`. Seluruh proses dieksekusi pada dataset Credit Card Fraud Detection yang diperoleh dari Kaggle dan telah melalui tahapan prapemrosesan sebagaimana telah dirancang pada Bab 3.

Untuk memastikan keterulangan eksperimen (reproducibility), seluruh luaran yang dihasilkan termasuk model terlatih, visualisasi, dan laporan performa — disimpan secara otomatis ke dalam direktori terstruktur (output/model, output/images, output/reports). Hasil penelitian juga dibandingkan dengan penelitian terdahulu yang telah dipetakan pada Tabel 2.1 untuk menunjukkan posisi keunggulan dan kontribusi dari model yang diusulkan.

4.1 Persiapan Data

Tahap persiapan data merupakan fondasi dari seluruh proses eksperimen. Pada penelitian ini, persiapan data dilaksanakan secara terprogram menggunakan bahasa Python versi terbaru dengan memanfaatkan pustaka `pandas` 2.3.3, `numpy` 2.2.6, dan `scikit-learn`. Seluruh tahapan dieksekusi secara berurutan dalam satu lingkungan notebook Jupyter yang terdokumentasi penuh.

4.1.1 Pengumpulan Data

Dataset yang digunakan dalam penelitian ini adalah Credit Card Fraud Detection yang diperoleh dari platform Kaggle dengan nama file `creditcard.csv`. Setelah berhasil dimuat ke dalam dataframe `df_raw`, dataset menunjukkan dimensi awal sebesar 284.807 baris transaksi dan 31 kolom atribut.

Seluruh 31 kolom bertipe numerik: 30 kolom bertipe `float64` dan 1 kolom (Class) bertipe `int64`. Untuk memberikan gambaran awal struktur data, lima baris pertama dataset menunjukkan rentang nilai yang bervariasi antar fitur — fitur `V1` hingga `V28` memiliki sebaran terpusat di sekitar nol (hasil transformasi PCA), sedangkan kolom `Amount` memiliki rentang nilai yang jauh lebih lebar.

Berdasarkan statistik deskriptif yang dihasilkan sistem, beberapa karakteristik penting dataset adalah sebagai berikut:

Tabel 4.1 Ringkasan Statistik Deskriptif Dataset Awal

Atribut	Min	Max	Mean	Std Dev
Time	0,00	172.792,00	94.813,86	47.488,15
V1–V28	bervariasi	bervariasi	$\approx 0,00$	0,33 – 1,96
Amount	0,00	25.691,16	88,35	250,12
Class	0	1	0,0017	0,04

Nilai rata-rata kolom Class sebesar 0,0017 mengkonfirmasi ketimpangan kelas yang sangat ekstrem hanya 492 dari 284.807 transaksi (0,17%) yang merupakan kasus fraud.

4.1.2 Pengolahan Data

Setelah dataset berhasil dimuat, dilakukan serangkaian tahapan pengolahan data yang dieksekusi secara terprogram. Berikut uraian tiap tahapan beserta hasil aktualnya.

1. Pemeriksaan Kualitas Data

Sistem melakukan inspeksi integritas data menggunakan dua fungsi utama. Pertama, `df_raw.isnull().sum()` untuk mendeteksi nilai kosong hasilnya menunjukkan bahwa seluruh 31 kolom memiliki nilai missing sebesar 0 (0,0%), yang berarti dataset memiliki kelengkapan pencatatan yang sempurna. Kedua, `df_raw.duplicated().sum()` untuk mendeteksi baris duplikat sistem berhasil mendeteksi 1.081 baris duplikat yang perlu dieliminasi.

2. Pembersihan Data

Berdasarkan temuan pemeriksaan kualitas, dilakukan dua langkah pembersihan:

- Deduplikasi menggunakan `df.drop_duplicates(inplace=True)` yang mengeliminasi 1.081 baris duplikat secara permanen. Proses ini mereduksi total data dari **284.807 baris menjadi 283.726 baris** bersih.
- imputasi defensif menggunakan `fillna(median_val)` untuk setiap kolom numerik. Meskipun tidak ada *missing value* pada dataset ini, langkah ini diterapkan agar *pipeline* tetap kokoh saat menerima data baru di masa depan.

2. Seleksi Fitur

Dari 31 kolom yang tersedia, dua kolom dieksklusi dari matriks pelatihan melalui `EXCLUDE_COLS = ['Class', 'Time']`. Kolom Class dieksklusi untuk mencegah kebocoran informasi (*data leakage*) karena Isolation Forest merupakan pendekatan *unsupervised*. Kolom Time dieksklusi karena urutan detik linier tidak memiliki korelasi kausal terhadap probabilitas terjadinya fraud.

Hasil seleksi menghasilkan **29 fitur numerik murni** yang menjadi matriks pelatihan, yaitu V1 hingga V28 ditambah kolom Amount.

3. Standardisasi Skala

Fitur-fitur V1–V28 memiliki sebaran terpusat di sekitar nol, sementara Amount memiliki rentang nilai hingga 25.691,16. Untuk menetralkan ketimpangan skala ini, seluruh 29 fitur dinormalisasi menggunakan `StandardScaler()` melalui perintah:

```
scaler = StandardScaler()
X_scaled = scaler.fit_transform(df_num)
```

Hasil standardisasi dikonfirmasi melalui statistik deskriptif setelah proses: seluruh 29 fitur menunjukkan nilai mean $\approx 0,0$ dan standar deviasi = 1,0. Matriks fitur final yang siap dilatih berukuran **283.726 baris $\times$ 29 kolom**.

Tabel 4.2 Ringkasan Hasil Tahapan Pengolahan Data

Tahapan	Input	Output	Keterangan
Load Dataset	—	284.807 $\times 31$	Dataset mentah dari Kaggle
Data Quality Check	284.807 baris	0 missing, 1.081 duplikat	Deteksi otomatis
Deduplikasi	284.807 baris	283.726 baris	Eliminasi 1.081 duplikat
Seleksi Fitur	31 kolom	29 fitur	Eksklusi Time & Class
Standardisasi	Skala bervariasi	$\mu \approx 0, \sigma = 1$	StandardScaler
Matriks Final	—	283.726 $\times 29$	Siap dilatih

4.2 Implementasi Teknik/Model

Tahap ini menjelaskan implementasi algoritma Isolation Forest secara penuh, mulai dari konfigurasi model, proses pelatihan, hingga penghitungan skor anomali untuk setiap transaksi.

4.2.1 Konfigurasi dan Pelatihan Model

Sebelum model dilatih, nilai parameter *contamination* dihitung secara otomatis dan dinamis langsung dari distribusi *ground truth* dataset yang telah dibersihkan, menggunakan formula:

```
contamination_rate = df["Class"].sum() / len(df)
```

Perhitungan ini menghasilkan nilai kontaminasi sebesar **0,001667** (473 kasus fraud dari 283.726 total data). Nilai ini kemudian digunakan sebagai parameter model sehingga ambang batas keputusan bersifat sepenuhnya *data-driven*.

Model Isolation Forest dikonfigurasi dan dilatih menggunakan kode berikut:

```
iso_forest = IsolationForest(  
    n_estimators=200,  
    contamination=contamination_rate,  
    random_state=42  
)  
iso_forest.fit(X_scaled)
```

Listing 4.1 Konfigurasi dan Pelatihan Model Isolation Forest

Penjelasan masing-masing parameter yang digunakan adalah sebagai berikut. Parameter `n_estimators=200` menetapkan jumlah pohon isolasi sebesar 200 — dua kali lipat dari nilai default scikit-learn (100) untuk menstabilkan estimasi skor anomali pada dataset berskala besar. Parameter `contamination=contamination_rate` menggunakan nilai yang dihitung dari rasio fraud riil (0,001667) sebagai estimasi proporsi anomali. Parameter `random_state=42` memastikan hasil eksperimen bersifat deterministik dan dapat direproduksi.

Setelah pelatihan selesai, model menghasilkan prediksi label untuk seluruh 283.726 transaksi menggunakan:

```
y_pred = iso_forest.predict(X_scaled) # 1 = Normal, -1 =  
Anomali
```

Listing 4.2 Prediksi Label Anomali

Hasil prediksi menunjukkan distribusi sebagai berikut:

Tabel 4.3 Distribusi Hasil Prediksi Model

Label	Jumlah Transaksi	Persentase
Normal (1)	283.253	99,83%

Anomali (-1)	473	0,17%
Total	283.726	100%

4.2.2 Penghitungan Skor Anomali

Selain label biner, model juga menghasilkan skor anomali kontinu (*anomaly score*) untuk setiap transaksi menggunakan `decision_function`. Skor ini mencerminkan tingkat kecurigaan setiap transaksi semakin rendah nilainya, semakin tinggi tingkat anomalnya.

```
scores = iso_forest.decision_function(X_scaled)
```

Listing 4.3 Penghitungan Skor Anomali

Distribusi skor anomali yang dihasilkan disajikan pada tabel berikut:

Tabel 4.4 Statistik Distribusi Skor Anomali

Statistik	Nilai
Skor tertinggi (paling normal)	0,311111
Skor terendah (paling anomali)	-0,112985
Rata-rata skor	0,252235
Standar deviasi	0,043589
Persentil 25%	0,236315
Median (50%)	0,262223
Persentil 75%	0,281531

Rentang skor yang dihasilkan berkisar antara -0,112985 hingga 0,311111. Transaksi yang memiliki skor di bawah ambang batas (mendekati atau di bawah 0) dikategorikan sebagai anomali, sedangkan transaksi dengan skor tinggi mendekati 0,311 diklasifikasikan sebagai transaksi normal.

4.2.3 Penyimpanan Model

Model yang telah dilatih beserta objek *scaler* disimpan dalam format serialisasi menggunakan pustaka `joblib` agar dapat digunakan kembali tanpa perlu melatih ulang dari awal:

```
joblib.dump(iso_forest, "output/model/isolation_forest.pkl") # 1.670,1 KB
joblib.dump(scaler, "output/model/standard_scaler.pkl") # 1,7 KB
```

Listing 4.4 Penyimpanan Model dan Scaler

Model dapat dimuat kembali dan digunakan untuk mendeteksi transaksi baru menggunakan kode berikut:

```
model = joblib.load("output/model/isolation_forest.pkl")
scaler = joblib.load("output/model/standard_scaler.pkl")
X_new_scaled = scaler.transform(X_new)
predictions = model.predict(X_new_scaled) # 1=Normal, -1=Anomali
```

Listing 4.5 Cara Memuat dan Menggunakan Kembali Model

4.3 Hasil dan Analisis

Bagian ini menyajikan hasil eksperimen secara menyeluruh, mulai dari interpretasi kinerja model berdasarkan metrik evaluasi, perbandingan dengan penelitian terdahulu, hingga pembahasan temuan-temuan penting yang diperoleh selama eksperimen.

4.3.1 Interpretasi Kinerja Model

a. Confusion Matrix

Sebelum metrik dihitung, dilakukan dua konversi label untuk menyamakan polaritas antara output model dan *ground truth*. Prediksi model dikonversi dari skema 1 = normal, -1 = anomali menjadi 1 = fraud, 0 = normal melalui operasi `np.where(y_pred == -1, 1, 0)`. Skor anomali dari `decision_function` dibalik tandanya (`y_score = -scores`) agar berlaku *semakin tinggi = semakin mirip fraud* untuk keperluan perhitungan AUCPR. Hasil *confusion matrix* yang diperoleh adalah sebagai berikut:

Tabel 4.5 Confusion Matrix Hasil Evaluasi Model

	Diprediksi Normal (0)	Diprediksi Fraud (1)
Aktual Normal (0)	282.887 (TN)	366 (FP)
Aktual Fraud (1)	366 (FN)	107 (TP)

Dari tabel di atas dapat dibaca:

- **TN = 282.887**: transaksi normal yang berhasil diprediksi benar sebagai normal.
- **FP = 366**: transaksi normal yang keliru diprediksi sebagai fraud (*false alarm*).

- **FN = 366:** transaksi fraud yang lolos tidak terdeteksi — ini adalah kesalahan paling kritis dalam konteks deteksi fraud.
- **TP = 107:** transaksi fraud yang berhasil terdeteksi dengan benar.

b. **Metrik Evaluasi**

Berdasarkan nilai-nilai pada *confusion matrix* di atas, seluruh metrik evaluasi dihitung dan disajikan pada tabel berikut:

Tabel 4.6 Hasil Metrik Evaluasi Model Isolation Forest

Metrik	Nilai	Keterangan
Accuracy	0,9974	99,74% prediksi benar secara keseluruhan
Precision	0,2264	22,64% dari yang diprediksi fraud memang benar fraud
Recall	0,2264	22,64% dari total fraud riil berhasil terdeteksi
F1-Score	0,2264	Keseimbangan Precision dan Recall
ROC-AUC	0,9484	Kemampuan diskriminasi model secara umum
AUCPR	0,1243	Kemampuan model mendeteksi kelas minoritas

Nilai *Accuracy* sebesar 99,74% terlihat sangat tinggi, namun angka ini tidak dapat dijadikan acuan utama karena dataset bersifat sangat tidak seimbang — model yang memprediksi semua transaksi sebagai normal pun akan menghasilkan akurasi di atas 99%. Oleh karena itu, perhatian utama diarahkan pada metrik AUCPR sebagai metrik primer.

Nilai **AUCPR sebesar 0,1243** mencerminkan tantangan nyata deteksi fraud pada dataset dengan ketimpangan kelas yang sangat ekstrem (0,17% fraud). Nilai ini menjadi titik referensi (*baseline*) yang penting untuk penelitian lanjutan yang dapat mengeksplorasi pendekatan *semi-supervised* atau teknik *resampling* seperti SMOTE untuk meningkatkan sensitivitas model terhadap kelas minoritas.

Nilai **ROC-AUC sebesar 0,9484** menunjukkan bahwa model memiliki kemampuan diskriminasi yang baik secara umum — model mampu membedakan antara transaksi normal dan fraud di 94,84% kasus jika dilihat dari perspektif *ranking*. Namun sebagaimana dijelaskan pada Bab 3, ROC-AUC pada dataset yang sangat tidak seimbang cenderung optimistis sehingga tidak dijadikan metrik primer.

4.3.2 Evaluasi Kinerja Model

Untuk menunjukkan posisi dan keunggulan penelitian ini, kinerja model dibandingkan dengan penelitian terdahulu yang menggunakan algoritma dan dataset serupa:

Tabel 4.7 Perbandingan Kinerja Model dengan Penelitian Terdahulu

Penelitian	Metode	Dataset	Metrik Utama	Nilai
Waspada et al. (2020)	Isolation Forest	Kaggle Credit Card	ROC-AUC	Tinggi (bias)
Zayer et al. (2026)	Isolation Forest + PCA	Kaggle Credit Card	Efisiensi komputasi	-
Vandana et al. (2023)	Isolation Forest	Kaggle Credit Card	Akurasi umum	-
Penelitian Ini	Isolation Forest	Kaggle Credit Card	ROC-AUC / AUCPR	0,9484 / 0,1243

Perbedaan mendasar penelitian ini dibandingkan Waspada et al. (2020) adalah pada aspek kelengkapan evaluasi penelitian ini melaporkan dua metrik sekaligus (ROC-AUC dan AUCPR) sehingga pembaca mendapat gambaran yang lebih jujur tentang performa model pada kelas minoritas, bukan hanya pada metrik yang terlihat tinggi. Dibandingkan Zayer et al. (2026), penelitian ini mempertahankan seluruh 29 fitur numerik tanpa reduksi PCA agresif, yang berpotensi menjaga informasi varians kecil yang kritis untuk identifikasi fraud.

4.3.3 Pembahasan Temuan

Terdapat beberapa temuan penting yang diperoleh dari hasil eksperimen ini.

- **Temuan 1 Precision dan Recall yang simetris**

Nilai Precision dan Recall yang sama persis (0,2264) merupakan fenomena menarik. Ini terjadi karena jumlah FP dan FN yang kebetulan sama (masing-masing 366). Artinya model menghasilkan jumlah *false alarm* yang sama dengan jumlah fraud yang lolos — sebuah kondisi yang menunjukkan model belum mampu mengoptimalkan salah satu di antara keduanya.

- **Temuan 2 Kontaminasi berbasis data terbukti konsisten**

Nilai `contamination_rate` yang dihitung dinamis dari ground truth menghasilkan nilai 0,001667, dan model mendeteksi tepat **473 transaksi sebagai anomali** — sangat mendekati jumlah fraud riil dalam dataset yaitu 473 (setelah

deduplikasi dari 492). Ini membuktikan bahwa pendekatan penetapan kontaminasi berbasis data menghasilkan ambang batas yang lebih presisi dibandingkan nilai arbitrer.

- **Temuan 3 AUCPR rendah adalah konsekuensi wajar ketimpangan ekstrem**

Nilai AUCPR 0,1243 tidak serta-merta berarti model gagal. Pada dataset dengan rasio fraud hanya 0,17%, nilai AUCPR di atas nilai *baseline* acak (yang setara dengan proporsi kelas positif $\approx 0,0017$) menunjukkan model masih memberikan informasi yang jauh lebih baik dari tebakan acak. Kondisi ini selaras dengan temuan Waspada et al. (2020) yang menegaskan bahwa AUCPR pada Isolation Forest *unsupervised* memang akan terbatas tanpa dukungan teknik penyeimbangan kelas.

- **Temuan 4 V1, Amount, dan V3 sebagai fitur paling berpengaruh**

Dari analisis korelasi absolut antara nilai fitur dan skor anomali, tiga fitur dengan pengaruh tertinggi adalah **V1, Amount, dan V3**. Dominasi V1 dan V3 (komponen PCA) mengindikasikan bahwa varians terbesar dalam pembentukan pola anomali berasal dari kombinasi fitur asli yang telah dienkapsulasi oleh komponen-komponen tersebut. Sementara dominasi Amount mengkonfirmasi hipotesis umum bahwa transaksi fraud cenderung memiliki nominal yang tidak lazim dibandingkan transaksi normal.

4.3.4 Hasil

Berdasarkan seluruh tahapan implementasi dan eksperimen yang telah dilakukan, model Isolation Forest berhasil dibangun dan dijalankan secara penuh pada dataset *Credit Card Fraud Detection* dengan 283.726 transaksi bersih. Model berhasil mengidentifikasi **473 transaksi** sebagai anomali (0,17%) dari keseluruhan data, dengan rincian **107 transaksi fraud terdeteksi benar (TP)** dari total 473 fraud riil yang ada.

Seluruh luaran eksperimen telah tersimpan secara otomatis ke dalam direktori terstruktur:

Tabel 4.8 Ringkasan Luaran Eksperimen

Jenis Luaran	Lokasi	Keterangan
Model terlatih	output/model/isolation_forest.pkl	1.670,1 KB
Scaler	output/model/standard_scaler.pkl	1,7 KB
Hasil deteksi	output/reports/anomaly_result.csv	283.726 baris × 32 kolom
Visualisasi	output/images/	9 file gambar

Visualisasi yang dihasilkan mencakup histogram distribusi fitur, *boxplot*, *correlation heatmap*, *scatter plot* PCA 2D dan 3D, distribusi anomali, distribusi skor anomali, kurva *Precision-Recall*, dan diagram *feature importance* — semuanya tersimpan otomatis tanpa intervensi manual sebagai wujud implementasi prinsip *reproducibility* yang menjadi salah satu kebaruan penelitian ini.

BAB 5

PENUTUP

Bab ini menyajikan kesimpulan akhir yang ditarik dari seluruh hasil penelitian dan pembahasan pada bab-bab sebelumnya, khususnya untuk menjawab ketiga rumusan masalah yang telah ditetapkan pada Bab 1. Selain itu, bab ini juga memuat saran-saran yang ditujukan bagi peneliti selanjutnya maupun pihak industri yang ingin mengembangkan atau mengimplementasikan sistem deteksi anomali berbasis *Isolation Forest* lebih lanjut.

5.1 Kesimpulan

Berdasarkan seluruh tahapan penelitian yang telah dilaksanakan — mulai dari pengumpulan data, prapemrosesan, implementasi model, hingga evaluasi hasil — dapat ditarik kesimpulan sebagai berikut:

1. **Tahapan implementasi algoritma Isolation Forest pada dataset transaksi kartu kredit** dilaksanakan melalui sebuah *pipeline* end-to-end yang terdiri dari lima tahap berurutan: pemeriksaan kualitas data (*Data Quality Check*), pembersihan data (*Data Cleaning*), seleksi fitur (*Feature Selection*), standardisasi skala (*Feature Scaling*), dan pelatihan model. Pada tahap pemeriksaan kualitas, sistem mendeteksi dan mengeliminasi 1.081 baris data duplikat dari total 284.807 baris, menghasilkan dataset bersih sebesar 283.726 baris. Selanjutnya, 29 fitur numerik murni (V1–V28 dan Amount) dipilih sebagai matriks pelatihan setelah mengeksklusi kolom Time dan Class. Seluruh fitur kemudian dinormalisasi menggunakan `StandardScaler` untuk menyamakan skala sebelum dilatihkan ke model `IsolationForest(n_estimators=200, contamination=0.001667, random_state=42)`.
2. **Kemampuan algoritma Isolation Forest dalam mendeteksi transaksi anomali** terbukti dapat beroperasi tanpa membutuhkan label historis fraud sama sekali. Dari 283.726 transaksi bersih, model berhasil mengidentifikasi 473 transaksi sebagai anomali (0,17%), di mana 107 di antaranya terkonfirmasi sebagai fraud riil (*True Positive*). Nilai **ROC-AUC sebesar 0,9484** menunjukkan kemampuan diskriminasi model yang baik secara umum, sementara nilai **AUCPR sebesar 0,1243** mencerminkan tantangan inherent deteksi kelas minoritas yang sangat langka pada dataset dengan ketimpangan kelas yang ekstrem.
3. **Performa model berdasarkan *confusion matrix* dan metrik evaluasi** menunjukkan bahwa model menghasilkan nilai *Accuracy* sebesar 99,74%, *Precision* sebesar

22,64%, *Recall* sebesar 22,64%, dan *F1-Score* sebesar 22,64%. Nilai *Precision* dan *Recall* yang simetris mengindikasikan bahwa jumlah *false alarm* (FP = 366) sama dengan jumlah fraud yang tidak terdeteksi (FN = 366). Kondisi ini merupakan karakteristik wajar dari pendekatan *unsupervised* pada dataset dengan rasio fraud hanya 0,17%, dan menegaskan rekomendasi Waspada et al. (2020) bahwa AUCPR adalah metrik yang lebih jujur dan representatif dibandingkan ROC-AUC untuk kasus serupa.

5.2 Saran

Berdasarkan hasil penelitian dan keterbatasan yang ditemukan selama eksperimen, berikut saran-saran yang dapat dijadikan acuan untuk pengembangan penelitian selanjutnya:

1. Eksplorasi teknik penyeimbangan kelas (*class balancing*).

Nilai AUCPR yang terbatas (0,1243) merupakan konsekuensi langsung dari ketimpangan kelas yang sangat ekstrem. Penelitian lanjutan disarankan untuk mengeksplorasi teknik *oversampling* seperti SMOTE (*Synthetic Minority Oversampling Technique*) atau *undersampling* pada tahap prapemrosesan untuk meningkatkan sensitivitas model terhadap kelas fraud sebelum pelatihan dilakukan.

2. Perbandingan dengan metode *unsupervised* lainnya.

Penelitian ini hanya mengevaluasi satu algoritma. Untuk mengukur keunggulan Isolation Forest secara lebih objektif, penelitian lanjutan dapat melakukan studi komparatif dengan algoritma deteksi anomali lain seperti *Local Outlier Factor*(LOF), *One-Class SVM*, atau *Autoencoder* berbasis *deep learning* pada dataset dan skema evaluasi yang sama.

3. Optimasi parameter melalui pencarian sistematis.

Parameter `n_estimators` dan `contamination` pada penelitian ini ditetapkan berdasarkan pertimbangan empiris. Penelitian lanjutan dapat menerapkan teknik pencarian parameter sistematis seperti *grid search* atau *Bayesian optimization* untuk menemukan kombinasi parameter yang menghasilkan nilai AUCPR optimal.

C. Penerapan pendekatan *semi-supervised*.

Karena dataset *Credit Card Fraud Detection* dari Kaggle sebenarnya memiliki label kelas (`Class`), penelitian lanjutan dapat mengeksplorasi pendekatan *semi-supervised* yang memanfaatkan sebagian kecil label yang tersedia untuk membimbing proses deteksi anomali, sehingga diharapkan menghasilkan *Recall* yang lebih tinggi tanpa mengorbankan *Precision* secara signifikan.

D. Penerapan pada data *streaming* secara *real-time*.

Penelitian ini dilakukan pada dataset statis (*batch processing*). Untuk aplikasi nyata di industri perbankan, sistem deteksi fraud harus mampu bekerja pada aliran data transaksi secara *real-time*. Penelitian lanjutan disarankan untuk mengadaptasi *pipeline* yang telah dibangun ke dalam arsitektur *streaming* menggunakan teknologi seperti Apache Kafka atau Apache Flink.

DAFTAR PUSTAKA

- Cherif, A., Badhib, A., Ammar, H., Alshehri, S., Kalkatawi, M., & Imine, A. (2020). Credit card fraud detection in the era of disruptive technologies: A systematic review. In *Journal of King Saud University - Computer and Information Sciences* (Vol. 35, Number 1, pp. 145–174). King Saud bin Abdulaziz University.
<https://doi.org/10.1016/j.jksuci.2022.11.008>
- Devicharan Rai M, & Jagadeesha S. N. (2023). Credit Card Fraud Detection using Machine Learning and Data Mining Techniques-a Literature Survey. *International Journal of Applied Engineering and Management Letters (IJAEML) A Refereed International Journal of Srinivas University*, 7(3), 2581–7000.
<https://doi.org/10.5281/zenodo.8190094>
- Liu, F. T., Ting, K. M., & Zhou, Z.-H. (2008). Isolation Forest. *2008 Eighth IEEE International Conference on Data Mining*, 413–422.
<https://doi.org/10.1109/ICDM.2008.17>
- Ounacer, S., Ait, H., Bour, E., Oubrahim, Y., Ghoumari, M. Y., & Azzouazi, M. (2018). *Using Isolation Forest in anomaly detection: the case of credit card transactions*. 6(2), 394–400. <http://pen.ius.edu.ba>
- Vandana, M., Divyanshu, T., Dhruv, M., & Tiwari, G. P. (2023). Fraud Detection using Isolation Forest Algorithm in Credit Card. In *International Journal of Humanities Social Science and Management (IJHSSM)* (Vol. 3, Number 1). www.ijhssm.org
- Waspada, I., Bahtiar, N., Wirawan, P. W., Dwi, B., & Awan, A. (2020). *Performance Analysis of Isolation Forest Algorithm in Fraud Detection of Credit Card Transactions* (Vol. 6, Number 2).
- Zayer, M. M., Saber, R. A., Kwyja, Y. M., & Abidi, A. I. (2026). *Outlier Detection in Credit Card Transactions Using Isolation Forest and PCA*.